

ÜSKÜDAR ÜNİVERSİTESİ

Mühendislik ve Doğa Bilimleri Fakültesi
Yapay Zeka Dersi

FINAL PROJECT REPORT

Radiomics-Based Papilledema Classification
Using Machine Learning

Hazırlayan

Abdulhamid R A Aburaïda

Oğrenci No: 234311901

Danışman / Instructor

Dr. GÖKALP TULUM

Haziran 2026

ÖZET

Bu projede papilödem hastalığının otomatik olarak sınıflandırılabilmesi amacıyla radyomik özellikler kullanılarak kapsamlı bir makine öğrenmesi sistemi geliştirilmiştir. Çalışmada normal göz görüntüleri ile papilödem vakasına ait görüntülerden elde edilen radyomik özellikler kullanılmıştır. Veri kümesi üzerinde eksik değerlerin giderilmesi, düşük varyansın elenmesi, yüksek korelasyonlu değişkenlerin kaldırılması ve RobustScaler ile ölçeklendirme işlemleri gerçekleştirilmiştir. Daha sonra Minimum Redundancy Maximum Relevance (MRMR) yöntemi kullanılarak en ayırt edici özellikler seçilmiştir. Model geliştirme aşamasında Logistic Regression, Support Vector Machine (RBF), Random Forest, Extra Trees, Gradient Boosting ve K-Nearest Neighbors algoritmaları değerlendirilmiştir. Ayrıca Random Forest, Extra Trees ve Gradient Boosting modellerinden oluşan olasılık tabanlı bir Soft Voting Ensemble modeli geliştirilmiştir. Modellerin hiperparametre optimizasyonu Optuna kütüphanesi kullanılarak Nested Cross Validation yapısı içerisinde gerçekleştirilmiştir. Model performansları Accuracy, Balanced Accuracy, Precision, Recall, Macro F1-Score, ROC-AUC, Precision-Recall AUC ve Brier Score ölçütleri ile değerlendirilmiştir. Modeller arasındaki istatistiksel farklar Friedman testi, Wilcoxon Signed-Rank testi ve Bonferroni düzeltmesi ile analiz edilmiştir.

1. GİRİŞ


Günümüzde yapay zeka ve makine öğrenmesi yöntemleri sağlık alanında tanı süreçlerini destekleyen önemli teknolojiler haline gelmiştir. Özellikle tıbbi görüntüleme alanında geliştirilen bilgisayar destekli tanı sistemleri, uzman hekimlerin karar verme süreçlerine katkı sağlayarak erken teşhis ve tedavi planlamasında önemli avantajlar sunmaktadır.

Papilödem, optik sinir başında meydana gelen ödem ile karakterize edilen ciddi bir göz hastalığının. Erken dönemde doğru şekilde teşhis edilmediği takdirde kalıcı görme kayıpları oluşabilmektedir. Bu nedenle papilödemın otomatik olarak tespit edilmesini sağlayan güvenilir sistemlerin geliştirilmesi büyük önem taşımaktadır.


Son yıllarda Radiomics yaklaşımı sayesinde tıbbi görüntülerden yüzlerce sayısal özellik elde edilebilmekte ve bu özellikler makine öğrenmesi algoritmaları tarafından sınıflandırma problemlerinde kullanılabilir. Bu proje kapsamında papilödem sınıflandırması için uçtan uca bir makine öğrenmesi sistemi geliştirilmiştir. Veri ön işleme, özellik seçimi, hiperparametre optimizasyonu, olasılık kalibrasyonu, topluluk öğrenmesi ve istatistiksel analiz aşamalarının tamamı tek bir çalışma akışı içerisinde gerçekleştirilmiştir.

2. VERİ KÜMESİ

Bu çalışmada papilödem sınıflandırma problemi için radyomik özelliklerden oluşan bir veri kümesi kullanılmıştır. Veri kümesi 48 benzersiz hastaya ait toplam 966 görüntüden oluşmaktadır. Normal bireyler için 672 görüntü, papilödem tanısı almış hastalar için ise 294 görüntü bulunmaktadır. Aynı hastaya ait birden fazla görüntü bulunabildiğinden hasta bazlı gruplama uygulanmış; aynı hastaya ait görüntüler hiçbir zaman hem eğitim hem de test kümesinde birlikte yer almamıştır. Her görüntü için 746 radyomik özellik çıkarılmıştır.



Sekil 1. Veri kümesindeki sınıf dagilimi (sol: örnek düzeyi, sag: hasta düzeyi)



Sekil 2. Hasta basina düşen görüntü sayısı dagilimi

3. VERİ ÖN ISLEME

Makine öğrenmesi modellerinin basarisi büyük ölçüde veri ön isleme asamasina baglidir. Siniflandirma modelleri egitlemeden önce radyomik özellikler üzerinde asagidaki kapsamli ön isleme süreci uygulanmistir:

3.1 Eksik Deger Analizi

Ilk asamada veri kümesindeki sonsuz (Inf) degerler NaN ile degistirilmis, ardindan tüm eksik degerler sütun bazinda medyan kullanilarak doldurulmustur. Medyan yöntemi aykirik degerlere karsi daha dayanikli

oldugu için tercih edilmistir.

3.2 Düşük Varyansın Kaldırılması

Çok düşük varyansa sahip özellikler (esik: 0.01) sınıflandırmaya anlamlı katkı sağlamadıkları için Variance Threshold yöntemi kullanılarak veri kümesinden çıkarılmıştır.

3.3 Korelasyon Filtresi

Pearson korelasyon katsayısı hesaplanmış ve belirlenen esik değerin (0.95) üzerinde korelasyona sahip özelliklerden yalnızca biri korunmuştur. Böylece çoklu doğrusal bağlantılık (Multicollinearity) problemi azaltılmıştır.

3.4 RobustScaler Normalizasyonu

Radiomics özellikleri farklı ölçeklerde bulunduğundan tüm değişkenler RobustScaler yöntemi kullanılarak normalize edilmiştir. RobustScaler; medyan ve çeyrekler arası acıklığı (IQR) kullanarak aykırı değerlere karşı dayanıklılık sağlamaktadır.

4. ÖZELLİK SEÇİMİ (MRMR)

Veri ön işleme sonrasında özellik seçimi amacıyla Minimum Redundancy Maximum Relevance (MRMR) algoritması uygulanmıştır. MRMR'nin temel amacı iki farklı kriteri aynı anda optimize etmektir:

- Hedef değişken ile yüksek ilişkiye sahip özellikleri seçmek (Relevance = Mutual Information)
- Birbirini tekrar eden (yüksek korelasyonlu) özellikleri mümkün olduğunca azaltmak (Redundancy = Mean Absolute Pearson Correlation)

Bu çalışmada MRMR algoritması kullanılarak her model için en iyi 15 özellik seçilmiş ve tüm sınıflandırıcılar bu özellik kümesi üzerinde değerlendirilmiştir. MRMR Nested Cross Validation yapısı içerisinde, yalnızca eğitim verisi üzerinde uygulanmıştır.

Tablo 1. Özellik Kararlılığı — En Yüksek Seçilme Sıklığına Sahip Özellikler

Model	Feature	Count	Pct
LogisticRegression	Feature_0479	5	100.0
LogisticRegression	Feature_0072	5	100.0
LogisticRegression	Feature_0478	5	100.0
LogisticRegression	Feature_0061	5	100.0
LogisticRegression	Feature_0442	5	100.0
LogisticRegression	Feature_0003	5	100.0
LogisticRegression	Feature_0028	5	100.0
LogisticRegression	Feature_0067	5	100.0
LogisticRegression	Feature_0010	5	100.0
LogisticRegression	Feature_0456	5	100.0
LogisticRegression	Feature_0647	5	100.0
LogisticRegression	Feature_0074	4	80.0
LogisticRegression	Feature_0626	3	60.0
LogisticRegression	Feature_0006	3	60.0

Model	Feature	Count	Pct
LogisticRegression	Feature_0476	2	40.0

Tablo 1: Farklı katlamalarda (fold) MRMR tarafından seçilen özelliklerin kararlılığı.

5. ÇALIŞMA AKISI (PIPELINE)

1. Veri yükleme ve etiketleme (Normal=0, Papilödem=1)
2. Inf değerlerin NaN ile değiştirilmesi
3. Medyan imputation
4. Variance Threshold (esik: 0.01)
5. Pearson Korelasyon Filtresi (esik: 0.95)
6. RobustScaler normalizasyonu
7. MRMR özellik seçimi (Top-15)
8. Nested Cross Validation (Dis: 5 Fold, Ic: 3 Fold)
9. Optuna hiperparametre optimizasyonu (50 deneme, TPE)
10. Model eğitimi (6 algoritma)
11. Sigmoid Kalibrasyon (Platt Scaling)
12. Soft Voting Ensemble (RF + ET + GB)
13. Performans değerlendirmesi (8 metrik)
14. İstatistiksel analiz (Friedman + Wilcoxon + Bonferroni)

Bu işlem akisi sayesinde veri sizintisi önlenmiş; tüm ön işleme adımları yalnızca eğitim verisi üzerinde öğrenilmiş ve test verisine aynı dönüşümler uygulanmıştır.

6. KULLANILAN MAKİNE ÖĞRENMESİ MODELLERİ

6.1 Logistic Regression

Doğrusal karar sınırı oluşturan temel sınıflandırma algoritmalarından biridir. Basit yapısı, düşük hesaplama maliyeti ve yorumlanabilirliği nedeniyle referans model olarak dahil edilmiştir.

6.2 Support Vector Machine (RBF Kernel)

Yüksek boyutlu veri kümelerinde başarılı sonuçlar veren güçlü bir sınıflandırıcıdır. Doğrusal olmayan karar sınırları öğrenebilmesi amacıyla Radial Basis Function (RBF) çekirdeği kullanılmıştır.

6.3 Random Forest

Çok sayıda karar ağacının birleştirilmesiyle oluşturulan topluluk yöntemidir. Bootstrap örnekleme ve rastgele özellik seçimi sayesinde asiri öğrenme (overfitting) önemli ölçüde azaltılmaktadır.

6.4 Extra Trees

Random Forest yöntemine benzetmekle birlikte, düğ bölünmeleri tamamen rastgele seçildiğinden daha fazla çeşitlilik oluşturmaktadır.

6.5 Gradient Boosting

Ardisik karar ağaçları oluşturarak önceki modellerin hataları düzeltmeye çalışan güçlü bir topluluk yöntemidir.

6.6 K-Nearest Neighbors (KNN)

Örnekler arasındaki uzaklığı temel alan parametrik olmayan bir sınıflandırıcıdır. RobustScaler uygulaması KNN performansı açısından kritik önem taşımaktadır.

7. HIPERPARAMETRE OPTİMİZASYONU VE NESTED CROSS VALIDATION


Makine öğrenmesi modellerinin performansı hiperparametre seçiminden önemli ölçüde etkilenmektedir. Bu nedenle tüm modeller için Optuna kütüphanesi kullanılarak otomatik hiperparametre optimizasyonu gerçekleştirilmiştir. Her model için 50 farklı kombinasyon değerlendirilmiş ve Macro F1 Score değerini maksimum yapan parametreler seçilmiştir. Optuna'nın Tree-structured Parzen Estimator (TPE) algoritması kullanılmıştır.

Model değerlendirme sürecinde yanlışlığı azaltmak amacıyla Nested Cross Validation yöntemi uygulanmıştır. Dis katman (Outer: 5 Fold) model performansını değerlendirmek, iç katman (Inner: 3 Fold) ise yalnızca hiperparametre optimizasyonu için kullanılmıştır. Bu yapı sayesinde test verisi hiçbir aşamada model seçim sürecine dahil edilmemiştir.

8. KALİBRASYON VE ENSEMBLE

8.1 Sigmoid Kalibrasyon (Platt Scaling)

Tüm modeller üzerinde Sigmoid Kalibrasyon (Platt Scaling) uygulanmıştır. Kalibrasyon işlemi sonrasında modellerin olasılık tahminleri Brier Score metriği kullanılarak değerlendirilmiştir.



Sekil 3. Kalibrasyon Egrileri — İdeal diyagonale yakınlık kalibrasyonun kalitesini gösterir

8.2 Soft Voting Ensemble (RF + ET + GB)

Tek bir model yerine birden fazla modelin birlikte kullanılması sınıflandırma performansını artırabilmektedir. Çalışmada Random Forest, Extra Trees ve Gradient Boosting modellerinden oluşan Soft Voting Ensemble

olusturulmustur. Her modelin kalibre edilmiş olasılık degerleri esit ağırlıklı ortalama alınarak nihai tahmin olusturulmustur. Bu yöntem sklearn VotingClassifier ile matematiksel olarak esdegordir.

Tablo 2. Ensemble Model Performansi

Model	Accuracy	Macro_F1	ROC_AUC
Ensemble (SoftVoting)	0.9056 ± 0.0640	0.8790 ± 0.0825	0.9229 ± 0.0705

Tablo 2: Soft Voting Ensemble modelinin çapraz doğrulama boyunca ortalama performansi.

9. DENEYSEL SONUÇLAR

9.1 Genel Model Karsilastirmasi

Tablo 3. Modellerin Ortalama Performans Özeti (Ortalama +/- Std)

Model	Accuracy	Balanced_Accu racy	Precision	Recall	Macro_F1	ROC_AUC	PR_AUC	Brier_Score
GradientBoosting	0.9058 +/- 0.0593	0.8614 +/- 0.0840	0.9110 +/- 0.0641	0.8614 +/- 0.0840	0.8789 +/- 0.0775	0.9137 +/- 0.0781	0.8947 +/- 0.0884	0.0787 +/- 0.0455
ExtraTrees	0.9018 +/- 0.0600	0.8585 +/- 0.0840	0.9018 +/- 0.0664	0.8585 +/- 0.0840	0.8745 +/- 0.0775	0.9263 +/- 0.0644	0.9010 +/- 0.0803	0.0747 +/- 0.0432
RandomForest	0.8995 +/- 0.0647	0.8548 +/- 0.0892	0.9010 +/- 0.0743	0.8548 +/- 0.0892	0.8712 +/- 0.0840	0.9218 +/- 0.0740	0.9016 +/- 0.0885	0.0774 +/- 0.0456
RBF_SVM	0.8884 +/- 0.0756	0.8512 +/- 0.0965	0.8770 +/- 0.0894	0.8512 +/- 0.0965	0.8617 +/- 0.0936	0.9232 +/- 0.0647	0.8882 +/- 0.0906	0.0832 +/- 0.0504
KNN	0.8925 +/- 0.0597	0.8424 +/- 0.0923	0.8955 +/- 0.0573	0.8424 +/- 0.0923	0.8587 +/- 0.0826	0.9096 +/- 0.0676	0.8697 +/- 0.0994	0.0868 +/- 0.0474
LogisticRegression	0.8699 +/- 0.0795	0.8220 +/- 0.1002	0.8639 +/- 0.0971	0.8220 +/- 0.1002	0.8363 +/- 0.0966	0.9015 +/- 0.0903	0.8744 +/- 0.1012	0.0948 +/- 0.0517

Tablo 3: Tüm katlamalar boyunca her model için ortalama performans degerleri (5-fold Nested CV).

Tablo 4. Tüm Modellerin Ayrıntili Performans Sonuçları

Model	Type	Accuracy	Balanced_Ac curacy	Precision	Recall	Macro_F1	ROC_AUC	PR_AUC	Brier_Score
Ensemble (RF+ET+GB)	Ensemble	0.9056	0.8617	0.9093	0.8617	0.879	0.9229	0.9008	0.0748
GradientBoosting	Individual	0.9058	0.8614	0.911	0.8614	0.8789	0.9137	0.8947	0.0787
ExtraTrees	Individual	0.9018	0.8585	0.9018	0.8585	0.8745	0.9263	0.901	0.0747
RandomForest	Individual	0.8995	0.8548	0.901	0.8548	0.8712	0.9218	0.9016	0.0774
RBF_SVM	Individual	0.8884	0.8512	0.877	0.8512	0.8617	0.9232	0.8882	0.0832
KNN	Individual	0.8925	0.8424	0.8955	0.8424	0.8587	0.9096	0.8697	0.0868
LogisticRegression	Individual	0.8699	0.822	0.8639	0.822	0.8363	0.9015	0.8744	0.0948

Tablo 4: Ensemble modeli dahil tüm modeller için nihai performans karsilastirmasi.

9.2 Fold Bazlı Sonuçlar

Tablo 5. Fold Bazlı Sonuçlar (Her Dis Katlamanın Performansı)


Model	Fold	Accuracy	Precision	Recall	Macro_F1	ROC_AUC
LogisticRegression	1	0.8929	0.9236	0.8179	0.852	0.962
LogisticRegression	2	0.8673	0.8702	0.7946	0.8207	0.8492

Model	Fold	Accuracy	Precision	Recall	Macro_F1	ROC_AUC
LogisticRegression	3	0.8476	0.8334	0.8179	0.8247	0.9454
LogisticRegression	4	0.9945	0.9912	0.996	0.9936	1.0
LogisticRegression	5	0.7473	0.7013	0.6835	0.6904	0.7507
RBF_SVM	1	0.9388	0.9454	0.9036	0.9215	0.9726
RBF_SVM	2	0.8469	0.8286	0.7804	0.7986	0.864
RBF_SVM	3	0.8762	0.8671	0.85	0.8575	0.9484
RBF_SVM	4	1.0	1.0	1.0	1.0	1.0
RBF_SVM	5	0.7802	0.7438	0.7222	0.7308	0.8312
RandomForest	1	0.9286	0.9545	0.875	0.9048	0.9777
RandomForest	2	0.8776	0.8672	0.8232	0.841	0.8309
RandomForest	3	0.9	0.9147	0.8607	0.8804	0.9671
RandomForest	4	0.9945	0.9912	0.996	0.9936	0.9999
RandomForest	5	0.7967	0.7774	0.7192	0.7365	0.8333
ExtraTrees	1	0.9184	0.9312	0.8679	0.8926	0.9517
ExtraTrees	2	0.8571	0.8545	0.7821	0.8069	0.8439
ExtraTrees	3	0.9095	0.9164	0.8786	0.8937	0.98
ExtraTrees	4	1.0	1.0	1.0	1.0	1.0
ExtraTrees	5	0.8242	0.8067	0.7639	0.7794	0.8559
GradientBoosting	1	0.9337	0.9575	0.8839	0.9122	0.9642
GradientBoosting	2	0.8878	0.8873	0.8304	0.8523	0.8284
GradientBoosting	3	0.9	0.9147	0.8607	0.8804	0.9651
GradientBoosting	4	0.9945	0.9912	0.996	0.9936	1.0
GradientBoosting	5	0.8132	0.8045	0.7361	0.7562	0.8107
KNN	1	0.8878	0.8721	0.8464	0.8578	0.8983
KNN	2	0.852	0.857	0.7679	0.7956	0.827
KNN	3	0.9095	0.927	0.8714	0.8918	0.9735
KNN	4	0.9945	0.9912	0.996	0.9936	1.0
KNN	5	0.8187	0.8303	0.7302	0.7546	0.8491

Tablo 5: Her modelin 5 farklı dis katlamadaki performansı — model kararlılığı analizi.

9.3 ROC Analizi


ROC eğrileri modellerin farklı karar eşiklerinde pozitif ve negatif sınıfı ayırabilme yeteneğini göstermektedir. Eğri altında kalan alan (ROC-AUC) modelin ayırt edicilik gücünü ifade eder.



Sekil 4. ROC Egrileri — Tüm Modeller

9.4 Precision-Recall Analizi

Papilödem gibi klinik problemlerde pozitif sınıfın doğru tahmini büyük önem tasimaktadır. Precision-Recall egrileri özellikle sınıf dengesizliginin olduğu durumlarda ek bilgi saglar.




Sekil 5. Precision-Recall Egrileri

9.5 Karisiklik Matrisleri

Her modelin doğru ve yanlış sınıflandırdığı örnekler karisiklik matrisi kullanılarak analiz edilmistir.


Confusion Matrices — All Models (Aggregated CV Predictions)



Sekil 6. Karışıklik Matrisleri — Tüm Modeller


9.6 Performans Karsilastirmasi

Model Comparison – Key Metrics



Sekil 7. Temel Metrik Karsilastirmasi


9.7 Ensemble Degerlendirmesi



Sekil 8. Ensemble Modeli — Karışıklık Matrisi ve ROC Egrisi

9.8 Özellik Kararlılığı


MRMR algoritması tarafından seçilen özelliklerin farklı katlamalarda ne kadar tutarlı olduğu incelenmiştir. Büyük çoğunluğunun tekrar seçilmesi radyomik özelliklerin kararlı bilgi taşıdığını gösterir.



Sekil 9. MRMR Özellik Kararlılığı

9.9 Macro F1 Score Dağılımı

Asagidaki kutu grafigi yalnızca ortalama basariyi degil, aynı zamanda performans degiskenligini de göstermektedir.



Sekil 10. Macro F1 Score Boxplot — Tüm Modeller

10. İSTATİSTİKSEL ANALİZ

Modeller arasındaki performans farklılıklarının istatistiksel olarak anlamlı olup olmadığını belirlemek amacıyla parametrik olmayan istatistiksel testler uygulanmıştır.

10.1 Friedman Testi

Tüm modeller aynı anda Friedman testi ile karşılaştırılmıştır. Friedman testi, aynı veri kümesi üzerinde değerlendirilen birden fazla sınıflandırıcı arasında genel bir fark olup olmadığını araştırmaktadır. $p < 0.05$ ise modeller arasında anlamlı fark olduğu kabul edilmektedir.

Tablo 6. Friedman Testi Sonuçları

Friedman Test	
Statistic	7.9448
p-value	0.1593
n_models=6, n_folds=5	

Tablo 6: Friedman testi sonuçları. p-değeri 0.05'ten büyük olduğu için modeller arasında istatistiksel olarak anlamlı bir fark tespit edilememiştir.

10.2 Wilcoxon Signed-Rank Testi ve Bonferroni Düzeltmesi

Friedman testi sonrasında modeller ikili olarak Wilcoxon Signed-Rank testi ile karşılaştırılmıştır. Çoklu karşılaştırmalarda yanlış pozitif sonuçları azaltmak amacıyla Bonferroni düzeltmesi uygulanmıştır (n=15 karşılaştırma).

Tablo 7. Wilcoxon Testi Sonuçları (Bonferroni Düzeltmeli)

Model_A	Model_B	Wilcoxon_stat	p_raw	p_bonferroni	Significant	Note
LogisticRegression	RBF_SVM	2.0	0.1875	1.0	No	
LogisticRegression	RandomForest	0.0	0.125	1.0	No	
LogisticRegression	ExtraTrees	2.0	0.1875	1.0	No	
LogisticRegression	GradientBoosting	0.0	0.125	1.0	No	
LogisticRegression	KNN	2.0	0.375	1.0	No	
RBF_SVM	RandomForest	5.0	0.625	1.0	No	
RBF_SVM	ExtraTrees	2.0	0.375	1.0	No	
RBF_SVM	GradientBoosting	3.0	0.3125	1.0	No	
RBF_SVM	KNN	7.0	1.0	1.0	No	
RandomForest	ExtraTrees	6.0	0.8125	1.0	No	
RandomForest	GradientBoosting	0.0	0.25	1.0	No	
RandomForest	KNN	3.0	0.625	1.0	No	
ExtraTrees	GradientBoosting	7.0	1.0	1.0	No	
ExtraTrees	KNN	0.0	0.0625	0.9375	No	
GradientBoosting	KNN	2.0	0.375	1.0	No	

Tablo 7: Tüm model çiftleri için Wilcoxon testi p-değerleri ve Bonferroni düzeltmeli sonuçlar.

11. TARTISMA

Bu çalışmada radyomik özellikler kullanılarak papilödem sınıflandırması için uçtan uca bir makine öğrenmesi sistemi geliştirilmiştir.

Veri ön işleme aşamalarının dikkatli şekilde uygulanması model performansının artırılmasında önemli rol oynamıştır. Özellikle eksik değerlerin giderilmesi, yüksek korelasyonlu değişkenlerin elenmesi ve RobustScaler kullanılması tüm modeller için daha kararlı sonuçlar elde edilmesini sağlamıştır.

MRMR algoritması, çok sayıdaki radyomik özellik içerisinde en ayırt edici değişkenlerin seçilmesine olanak sağlamıştır. Nested Cross Validation yapısı sayesinde hiperparametre optimizasyonu ile model değerlendirme süreci birbirinden ayrılmış, performans tahminlerinde oluşabilecek iyimser yanlılık önemli ölçüde azaltılmıştır.

Soft Voting Ensemble yaklaşımı tek bir modele bağımlılık azaltarak daha dengeli tahminler üretmiştir. İstatistiksel analiz sonuçları modeller arasındaki performans farklılıklarının istatistiksel olarak anlamlı olmadığını göstermiş; bu durum veri kümesinin küçük boyutundan kaynaklanmış olabilir.

Çalışmanın sınırlılığı olarak veri kümesinin tek bir kaynaktan elde edilmiş olması gösterilebilir. Gelecekte daha büyük ve çok merkezli veri kümeleri ile yapılacak çalışmalar modellerin genellenebilirliğini artıracaktır.

12. SONUÇ

Bu projede papilödem sınıflandırması amacıyla radyomik özellikler kullanılarak kapsamlı bir makine öğrenmesi sistemi başarıyla geliştirilmiştir. Altı farklı makine öğrenmesi algoritması ve bir Soft Voting Ensemble modeli karşılaştırılmış; performans değerlendirmeleri sekiz farklı metrik kullanılarak gerçekleştirilmiştir. En yüksek Macro F1 Score değeri Gradient Boosting modeli tarafından (0.8789) elde edilmiştir. Ensemble modeli (RF+ET+GB) ise 0.8790 Macro F1 ve 0.9229 ROC-AUC değerleriyle dengeli ve güvenilir sonuçlar üretmiştir. Geliştirilen çalışma akisi yalnızca bu veri kümesi için değil, benzer tıbbi

görüntü sınıflandırma problemleri için de uygulanabilecek genel bir metodoloji sunmaktadır.

KAYNAKÇA

- [1] Gillies RJ, Kinahan PE, Hricak H. Radiomics: Images Are More than Pictures, They Are Data. Radiology. 2016.
- [2] Lambin P, et al. Radiomics: Extracting more information from medical images using advanced feature analysis. European Journal of Cancer. 2012.
- [3] van Griethuysen JJM, et al. Computational Radiomics System to Decode the Radiographic Phenotype. Cancer Research. 2017.
- [4] Breiman L. Random Forests. Machine Learning. 2001.
- [5] Friedman JH. Greedy Function Approximation: A Gradient Boosting Machine. Annals of Statistics. 2001.
- [6] Cortes C, Vapnik V. Support Vector Networks. Machine Learning. 1995.
- [7] Pedregosa F, et al. Scikit-learn: Machine Learning in Python. JMLR. 2011.
- [8] Akiba T, et al. Optuna: A Next-generation Hyperparameter Optimization Framework. KDD. 2019.
- [9] Kuhn M, Johnson K. Applied Predictive Modeling. Springer.
- [10] Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning. Springer.